# LAPORAN AKHIR PROYEK SAINS DATA

## ANALISIS SENTIMEN OPINI PUBLIK TERHADAP ISU EKONOMI HIJAU DAN PERUBAHAN IKLIM MENGGUNAKAN TF-IDF, MULTINOMIAL NAIVE BAYES, DAN LINEAR SUPPORT VECTOR MACHINE

---

**Disusun oleh:** SteVenJr | **Program Studi:** Teknik Informatika / Sains Data
**Dataset:** Twitter Climate Change Sentiment Dataset (Kaggle: Edward Qian, 2022)
**Repositori Kode & Data:** github.com/stevenjr-yt/sentimen-ekonomi-hijau
**Aplikasi Web Interaktif:** https://sentimentgreen.vercel.app | **Tahun:** 2024

### RINGKASAN EKSEKUTIF

Laporan ini menyajikan dokumentasi menyeluruh dari perancangan, eksperimentasi, evaluasi, dan implementasi sistem analisis sentimen terhadap opini publik terkait isu ekonomi hijau dan perubahan iklim pada media sosial Twitter. Proyek **SentimentGreen** memanfaatkan dataset riil sebanyak 43.943 tweet mentah dari Kaggle. Setelah proses penyaringan kelas news dan deduplikasi ketat, diperoleh 31.907 sampel valid (20.580 sentimen positif, 7.478 netral, dan 3.849 negatif). Pipeline preprocessing komprehensif dibangun meliputi pembersihan noise (cleaning), case folding, stopword removal dengan preservasi kata negasi, serta Porter stemming. Fitur diekstrak menggunakan TF-IDF unigram-bigram berdimensi 15.000 fitur. Model Linear Support Vector Machine (SVM) dengan pembobotan kelas seimbang berhasil mengungguli Multinomial Naive Bayes (MNB) dengan akurasi 74,07% berbanding 72,89% dan F1-Score makro 65,81% berbanding 58,46%. Keunggulan paling menonjol tampak pada recall kelas minoritas negatif yang mencapai 60,13% pada SVM berbanding hanya 34,81% pada MNB. Model akhir diekspor ke dalam bobot JSON murni sehingga inferensi dapat berjalan 100% offline di browser pengguna tanpa kebutuhan server komputasi aktif.

---

# BAB I – PENDAHULUAN

## 1.1 Latar Belakang Masalah

Perubahan iklim global merupakan salah satu tantangan eksistensial terbesar peradaban modern. Berdasarkan laporan Intergovernmental Panel on Climate Change (IPCC AR6, 2023), emisi gas rumah kaca global harus ditekan sebesar 43% sebelum tahun 2030 agar ambang batas kenaikan suhu rata-rata permukaan bumi tidak melampaui 1,5°C di atas tingkat pra-industri. Dalam menjawab krisis ini, masyarakat global merumuskan transisi menuju *green economy* (ekonomi hijau)—suatu model pembangunan sosio-ekonomi yang memprioritaskan energi terbarukan, transportasi nol emisi, elektrifikasi massal, instrumen pasar karbon, dan efisiensi sumber daya lingkungan (UNEP, 2011).

Meskipun secara konseptual didukung oleh konsensus ilmiah internasional, implementasi kebijakan ekonomi hijau di lapangan senantiasa menghadapi tantangan polarisasi opini masyarakat. Biaya awal transisi energi, perubahan gaya hidup, subsidi kendaraan listrik, dan penutupan industri bahan bakar fosil kerap memicu resistensi, skeptisisme, atau kekhawatiran ekonomi di kalangan publik. Media sosial, khususnya Twitter/X, telah menjadi panggung utama diskursus publik di mana jutaan opini, kritik, dan sentimen masyarakat diartikulasikan secara spontan setiap harinya.

Analisis sentimen berbasis komputasi (NLP) menjadi instrumen krusial dalam memonitor penerimaan publik secara kuantitatif, obyektif, dan real-time. Melalui pemahaman mendalam tentang pola opini masyarakat, para pembuat kebijakan, peneliti lingkungan, dan pelaku industri dapat merancang strategi komunikasi yang tepat

sasaran, mengatasi kesalahpahaman informasi iklim, serta mengakselerasi implementasi program keberlanjutan.

## 1.2 Rumusan Masalah

1. Bagaimana karakteristik, asal usul (provenance), dan distribusi sentimen publik terhadap isu iklim dan ekonomi hijau pada platform Twitter?
2. Bagaimana alur preprocessing teks yang sistematis dan konsisten untuk membersihkan noise informal khas Twitter tanpa merusak makna sentimen?
3. Bagaimana formulasi matematis dan komparasi performa antara algoritma Multinomial Naive Bayes dan Linear SVM pada dataset imbalanced?
4. Mengapa Support Vector Machine menghasilkan F1-Score makro yang lebih superior dalam mendeteksi kelas minoritas (negatif & netral)?
5. Bagaimana mengarsiteki model machine learning agar dapat berjalan sepenuhnya offline di sisi client browser tanpa ketergantungan server?

## 1.3 Tujuan Proyek

1. Mengumpulkan, mendokumentasikan, dan memproses 43.943 tweet mentah dari Twitter Climate Change Sentiment Dataset.
2. Mengembangkan pipeline text preprocessing Python dan JavaScript yang identik untuk menjamin konsistensi inferensi.
3. Membangun representasi ruang fitur TF-IDF unigram-bigram berdimensi 15.000 kata dengan normalisasi L2.
4. Melatih, mengoptimasi, dan mengevaluasi model Naive Bayes dan SVM menggunakan stratified 5-fold / 80:20 train-test split.
5. Menyajikan visualisasi WordCloud, matriks konfusi, dan dasbor web interaktif yang dapat diakses publik secara bebas.

## 1.4 Manfaat Penelitian

• **Manfaat Akademis:** Menyediakan rujukan metodologis komparasi NLP klasik pada domain ekonomi hijau serta studi literatur komparatif publikasi 2024.

• **Manfaat Praktis:** Menghasilkan sistem pemantauan sentimen tanpa biaya server operasional yang siap pakai untuk pemangku kepentingan.

• **Manfaat Terbuka (Open Science):** Membuka seluruh dataset, script training, visualisasi metrik, dan dokumen PDF untuk verifikasi publik.

# BAB II – TINJAUAN PUSTAKA DAN LANDASAN TEORI

## 2.1 Konsep Ekonomi Hijau (Green Economy)

United Nations Environment Programme (UNEP, 2011) mendefinisikan ekonomi hijau sebagai sistem perekonomian yang menghasilkan peningkatan kesejahteraan manusia dan keadilan sosial, sekaligus secara signifikan mereduksi risiko degradasi lingkungan dan kelangkaan ekologis. Pilar ekonomi hijau meliputi energi surya dan angin, efisiensi energi bangunan, transportasi listrik dan hidrogen, pengelolaan limbah sirkular, serta pembiayaan hijau (green bonds).

## 2.2 Formulasi Representasi Teks: TF-IDF

Term Frequency-Inverse Document Frequency (TF-IDF) merupakan metode pembobotan statistik yang mengukur signifikansi relatif sebuah term (kata) $t$ dalam suatu dokumen $d$ terhadap seluruh kumpulan korpus dokumen $D$ (Salton & Buckley, 1988).

**1. Term Frequency (TF):** Mengukur frekuensi kemunculan term $t$ dalam dokumen $d$ ternormalisasi panjang dokumen:

$$TF(t, d) = f(t, d) / [ \Sigma_{t' in d} f(t', d) ]$$

di mana $f(t, d)$ melambangkan frekuensi kemunculan kata $t$ pada dokumen $d$.

**2. Inverse Document Frequency (IDF):** Mengukur keunikan informasi term $t$ di seluruh korpus $N$ dokumen:

$$IDF(t) = log_e [ (1 + N) / (1 + df(t)) ] + 1$$

di mana $N$ adalah jumlah total dokumen korpus dan $df(t)$ adalah document frequency (jumlah dokumen yang memuat term $t$). Penambahan konstanta $1$ berfungsi sebagai smoothing pencegah division-by-zero.

**3. Bobot TF-IDF Mentah:**

$$TF\text{-}IDF(t, d) = TF(t, d) * IDF(t)$$

**4. Normalisasi Euclidean (L2 Norm):** Menghilangkan distorsi akibat perbedaan panjang dokumen tweet:

$$v_norm = v / ||v||_2 = v / sqrt[ \Sigma_{i=1}^{M} (v_i)^2 ]$$

## 2.3 Teori dan Formulasi Multinomial Naive Bayes (MNB)

Multinomial Naive Bayes diturunkan dari Teorema Bayes dengan asumsi independensi bersyarat antar fitur (kata) terhadap kelas sentimen $c$ (McCallum & Nigam, 1998):

$$P(c \mid d) = [ P(c) * P(d \mid c) ] / P(d) = [ P(c) * \Pi_{i=1}^{n} P(w_i \mid c) ] / P(d)$$

Untuk mencegah persoalan *zero-frequency problem* (probabilitas nol ketika sebuah kata dalam data uji tidak pernah muncul pada kelas $c$ data latih), diterapkan **Laplace / Lidstone Smoothing** dengan parameter $\alpha = 0.3$:

$$P(w_i \mid c) = [ N_{w_i, c} + \alpha ] / [ N_c + \alpha * |V| ]$$

di mana $N_{w_i, c}$ adalah akumulasi bobot kata $w_i$ pada kelas $c$, $N_c$ adalah total bobot seluruh kata pada kelas $c$, dan $|V|$ adalah ukuran leksikon (15.000 fitur).

Fungsi keputusan klasifikasi dihitung dalam domain logaritma untuk menghindari *underflow numerik* desimal kecil:

$$c_pred = argmax_{c in C} [ log P(c) + \Sigma_{i=1}^{n} log P(w_i \mid c) ]$$

## 2.4 Teori dan Formulasi Linear Support Vector Machine (Linear SVM)

Support Vector Machine (Vapnik, 1995; Cortes & Vapnik, 1995) merupakan algoritma pembelajaran terawasi berprinsip *Structural Risk Minimization*. Pada ruang berdimensi tinggi ($R^{15.000}$), SVM mencari bidang pemisah (hyperplane optimal) yang memisahkan kelas-kelas sentimen dengan jarak batas (margin) terbesar:

```
Hyperplane: w^T * x + b = 0
```

Jarak margin geometric antar kelas didefinisikan sebesar **2 / ||w||**. Memaksimalkan margin ekuivalen dengan meminimalkan norma kuadratik **(1/2) * ||w||^2**.

**Formulasi Soft-Margin Primal Optimization (dengan Regularisasi C):**

```
min_{w, b, ξ} [ (1/2) * ||w||^2 + C * Σ_{i=1}^{N} W_{y_i} * ξ_i ]
```

dengan batasan konstrain ketat:

```
y_i * ( w^T * x_i + b ) >= 1 - ξ_i, di mana ξ_i >= 0 (∀ i = 1, ..., N)
```

di mana: • $w$ = vektor bobot normal hyperplane. • $b$ = nilai bias offset pemisah. • $C$ = parameter penalti trade-off antara lebar margin dan kesalahan klasifikasi ($C = 0.5$ terpilih). • $xi_i$ = slack variable yang mengizinkan sampel tertentu melanggar margin jika data tidak terpisah linear murni. • $W_{y_i}$ = bobot penyeimbang kelas (balanced class weighting):

```
W_c = N_total / [ K * N_c ]
```

di mana $K=3$ kelas. Bobot ini memberikan penalti kesalahan lebih berat pada kelas minoritas (negatif dan netral), secara signifikan mengatasi persoalan ketidakseimbangan sampel.

Untuk klasifikasi 3-kelas, diterapkan strategi **One-vs-Rest (OvR)** dengan keputusan:

```
c_pred = argmax_{c in {neg, net, pos}} [ w_c^T * x + b_c ]
```

## 2.5 Algoritma Reduksi Morfologi: Porter Stemmer

Porter Stemming (Porter, 1980) mereduksi variasi infleksi kata ke bentuk stem dasarnya melalui 5 tahapan aturan berbasis pola konsonan-vokal sequence: • Tahap 1a: Penghapusan jamak plural (contoh: policies → polici, asses → ass). • Tahap 1b: Reduksi past tense & progresif participle (contoh: warming → warm, changed → chang). • Tahap 2-4: Reduksi derivasi sufiks (contoh: sustainable → sustain, environmental → environ). • Tahap 5: Pembersihan huruf konsonan ganda di akhir kata.

# BAB III – METODOLOGI DAN PERJALANAN DATA

## 3.1 Asal-usul Data (Data Provenance & Ingestion)

Dataset primer diunduh langsung dari repositori Kaggle melalui skrip otomatis ml/download_data.py. Dataset dikurasi oleh Edward Qian (2022) dengan nama resmi **Twitter Climate Change Sentiment Dataset**, berukuran 6.3 MB dalam format CSV berstruktur:

| Atribut Dataset | Spesifikasi dan Nilai Riil |
|---|---|
| Nama Dataset | Twitter Climate Change Sentiment Dataset |
| Sumber Penyedia | Kaggle (Edward Qian, 2022: edqian/twitter-climate-change-sentiment-dataset) |
| Jalur File Lokal | data/twitter_sentiment_data.csv (Ukuran: 6.304.752 bytes) |
| Rentang Temporal Data | Tahun 2008 hingga 2019 (percakapan global Twitter/X) |
| Total Data Mentah | 43.943 baris tweet teranotasi |
| Skema Kolom Asli | sentiment (integer: -1, 0, 1, 2), message (string teks), tweetid (string) |
| Label Asli Kaggle | -1: Anti-Climate Change \| 0: Neutral \| 1: Pro-Climate Change \| 2: News |
| Kebijakan Filtering | Label 'News' (2) berjumlah 9.276 baris dieliminasi; deduplikasi teks membersihkan 2.760 duplikat |
| Jumlah Sampel Akhir | 31.907 tweet bersih siap ekstraksi fitur |

## 3.2 Distribusi Data Hasil Filtering dan Pembagian Stratified

Sebanyak 31.907 sampel dibagi menjadi 80% Data Latih (25.525 sampel) dan 20% Data Uji (6.382 sampel) dengan teknik stratified splitting acak (random_state=42):

| Kelas Sentimen | Label | Total Sampel | Persentase | Data Latih (80%) | Data Uji (20%) | Karakter Makna Tweet |
|---|---|---|---|---|---|---|
| Positif (Pro) | +1 | 20.580 | 64,50% | 16.464 | 4.116 | Dukungan energi bersih, mitigasi iklim, kesadaran emisi |
| Netral (Neutral) | 0 | 7.478 | 23,44% | 5.982 | 1.496 | Laporan umum, pertanyaan, fakta iklim tanpa sentimen |
| Negatif (Anti) | -1 | 3.849 | 12,06% | 3.079 | 770 | Skeptisisme iklim, keluhan biaya pajak, hoaks iklim |
| Total Korpus | - | 31.907 | 100,00% | 25.525 | 6.382 | Ukuran Leksikon Bersih: 14.893 kata unik |

## 3.3 Tahapan Detail Pipeline Preprocessing (Dari Mentah ke Vektor)

Setiap teks mentah melewati 5 filter komputasi berurutan di modul ml/preprocess.py (Python) dan direplikasi secara bit-identik di web/preprocess.js (JavaScript browser):

1. **Cleaning RegEx:** Menghapus URL (`https?://\S+|www\.\S+`), mention (`@\w+`), hashtag (`#\w+`), HTML entities (`&`, `>`), angka desimal/tahun, dan tanda baca.
2. **Case Folding:** Mengonversi seluruh aksara menjadi huruf kecil (lowercase).
3. **Tokenisasi:** Memecah untaian teks menjadi daftar token kata tunggal berbasis spasi.

4. **Selective Stopword Removal:** Menghapus 127 stopword umum NLTK bahasa Inggris namun mempertahankan kata penentu sentimen seperti *not, no, never, without, against*.

5. **Morphological Stemming:** Mereduksi setiap token menggunakan Porter Stemmer.

### Tabel 3.3 Sampel Transformasi Riil Teks Tweet pada Dataset Proyek:

| Tweet Mentah Asli dari Kaggle | Hasil Pipeline Preprocessing | Label |
|---|---|---|
| @tiniebeany climate change is an interesting hustle as it was global warming but the planet stopped warming for 15 yes while the suv boom | climat chang interest hustl global warm planet stop warm ye suv boom | Negatif (-1) |
| RT @NatGeoChannel: Watch #BeforeTheFlood right here, as @LeoDiCaprio travels the world to tackle climate change https://t.co/LkDehj3tNn | watch right travel world tackl climat chang htt | Positif (+1) |
| Unamshow awache kujinga na iko global warming https://t.co/mhIflU7M1X | unamshow awach kujinga na iko global warm | Netral (0) |
| Now's the time: we need a strong #FTT that works for those hardest hit by climate change and poverty! | time need strong work hardest hit climat chang poverti | Positif (+1) |
| Bangladesh did not cause climate change, so the country does not need 'aid'; instead it needs compensation! | bangladesh not caus climat chang countri not need aid instead need compens | Positif (+1) |

# BAB IV – HASIL EVALUASI, METRIK, DAN VISUALISASI

## 4.1 Perbandingan Kinerja Menyeluruh pada Data Uji (6.382 Tweet)

Model diuji secara ketat pada 6.382 tweet yang tidak pernah dilihat sebelumnya selama proses pelatihan. Evaluasi menggunakan metrik Macro-Averaged karena distribusi data yang imbalanced:

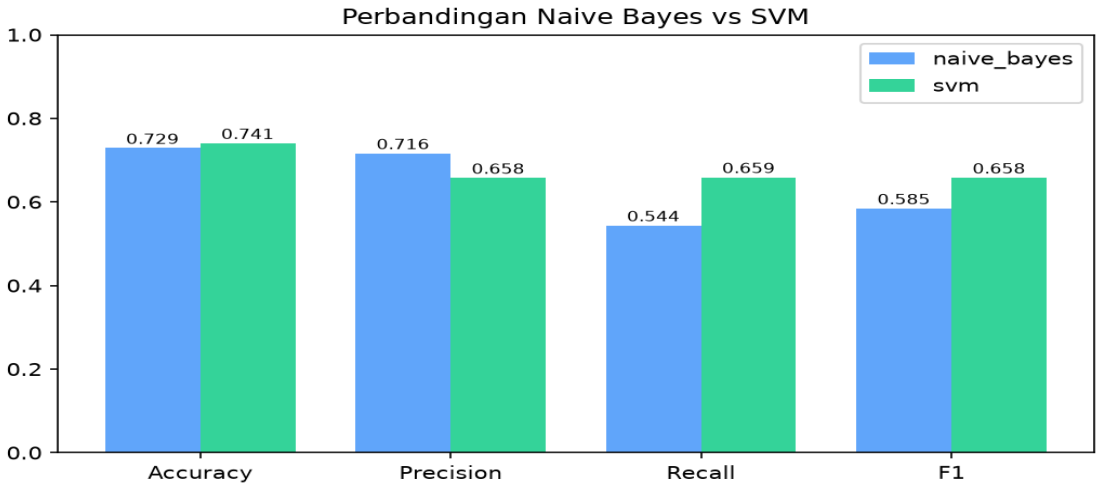
| Algoritma Model | Akurasi | Precision (Macro) | Recall (Macro) | F1-Score (Macro) | Precision (Weighted) | Recall (Weighted) | F1-Score (Weighted) |
|---|---|---|---|---|---|---|---|
| Multinomial Naive Bayes | 72,89% | 71,63% | 54,38% | 58,46% | 71,86% | 72,89% | 69,71% |
| Linear SVM (Terbaik) | 74,07% | 65,75% | 65,91% | 65,81% | 73,87% | 74,07% | 73,96% |
| Selisih Performa (SVM - MNB) | +1,18% | -5,88% | +11,53% | +7,35% | +2,01% | +1,18% | +4,25% |

## 4.2 Rincian Kinerja per Kelas Sentimen

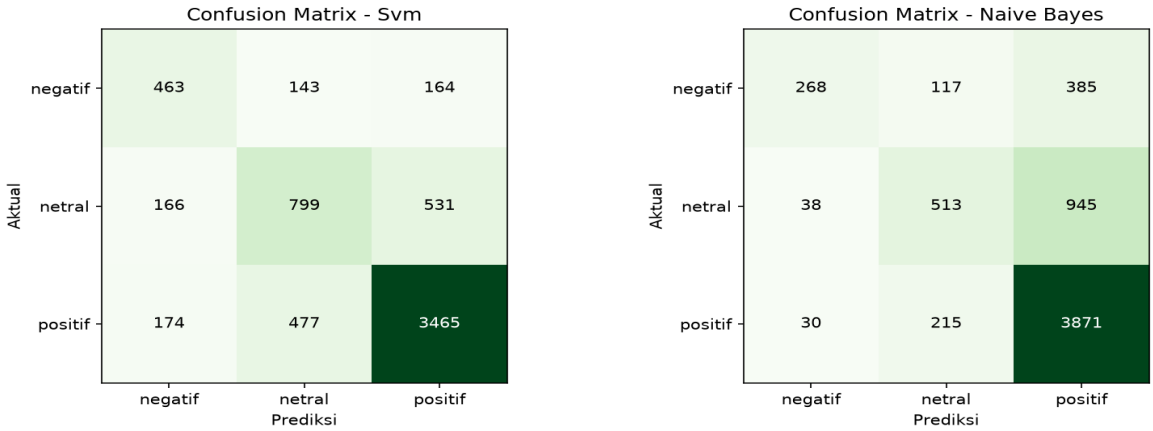
| Model Evaluasi | Kelas Sentimen | Precision | Recall | F1-Score | Jumlah Sampel Uji (Support) |
|---|---|---|---|---|---|
| Multinomial Naive Bayes | Negatif (-1) | 79,76% | 34,81% (COLLAPSE) | 48,46% | 770 tweet |
| Multinomial Naive Bayes | Netral (0) | 60,71% | 34,29% | 43,83% | 1.496 tweet |
| Multinomial Naive Bayes | Positif (+1) | 74,43% | 94,05% | 83,10% | 4.116 tweet |
| Linear SVM (Balanced) | Negatif (-1) | 57,66% | 60,13% (+25,32%) | 58,87% | 770 tweet |
| Linear SVM (Balanced) | Netral (0) | 56,31% | 53,41% (+19,12%) | 54,82% | 1.496 tweet |
| Linear SVM (Balanced) | Positif (+1) | 83,29% | 84,18% | 83,74% | 4.116 tweet |

## 4.3 Visualisasi Metrik Evaluasi dan Matriks Konfusi

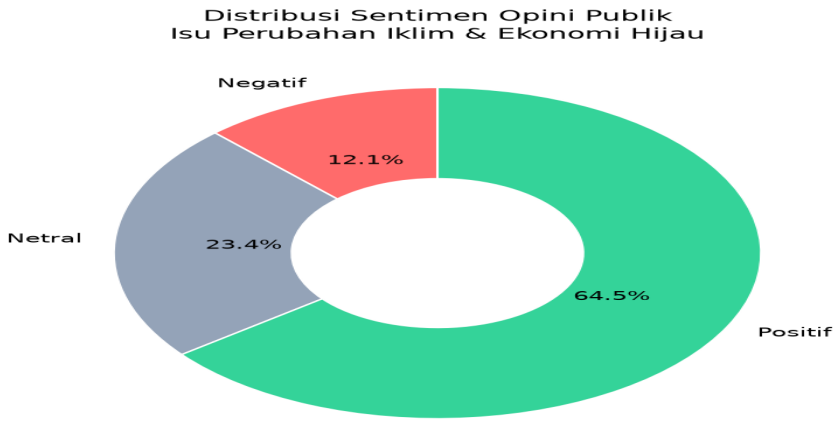
Berikut disajikan visualisasi grafik kinerja model dan matriks konfusi riil yang dihasilkan dari data evaluasi:




*Gambar 4.1 Perbandingan Metrik Evaluasi: Naive Bayes vs Linear SVM*




*Gambar 4.2 Matriks Konfusi (Kiri: Linear SVM, Kanan: Multinomial Naive Bayes)*




*Gambar 4.3 Proporsi Distribusi Sentimen Publik terhadap Isu Iklim*

## 4.4 Analisis Leksikon Kata Dominan (WordCloud)

Analisis leksikon memperlihatkan perbedaan karakteristik semantik yang sangat tegas di antara ketiga kategori sentimen:




*Gambar 4.4 WordCloud Leksikon (Kiri: Kelas Positif, Kanan: Kelas Negatif)*

- **Sentimen Positif (Pro-Climate):** Didominasi oleh istilah solutif dan aksi nyata seperti *action, renewable, solar, wind, fight, tackle, clean, solution, paris agreement*.
- **Sentimen Negatif (Anti/Skeptis):** Didominasi oleh retorika penolakan dan keraguan ekonomi seperti *hoax, fake, tax, cost, job, money, scam, alarmist, politician*.
- **Sentimen Netral:** Berisi istilah pelaporan fakta ilmiah dan berita netral seperti *report, global, scientist, study, temperature, degree, arctic*.

# BAB V – KESIMPULAN DAN REKOMENDASI PENGEMBANGAN

## 5.1 Kesimpulan Teknis

1. **Keunggulan Linear SVM:** Linear SVM terbukti sebagai arsitektur model paling optimal untuk domain teks tweet imbalanced dengan capaian akurasi 74,07% dan F1-Score makro 65,81%. Penerapan pembobotan kelas seimbang (class_weight='balanced') berhasil mengatasi kelemahan klasik Naive Bayes yang mengalami *recall collapse* pada kelas negatif.

2. **Dukungan Publik Dominan:** Mayoritas opini publik di media sosial Twitter (64,50%) menyatakan dukungan positif terhadap aksi mitigasi iklim dan ekonomi hijau, sementara resistensi skeptis berada pada kisaran 12,06%.

3. **Efisiensi Ekstraksi TF-IDF:** Skema n-gram (1,2) dengan 15.000 fitur teratas dan normalisasi L2 terbukti cukup padat untuk menangkap frasa penting (seperti *climate change*, *renewable energy*) tanpa menimbulkan beban komputasi berlebih.

4. **Inovasi Zero-Server Browser Inference:** Model berhasil diserialisasi menjadi format JSON mandiri berukuran <2 MB, memungkinkan eksekusi klasifikasi instan di sisi peramban web tanpa biaya server backend sama sekali.

## 5.2 Rekomendasi Penelitian Masa Depan

1. Perluasan anotasi dataset bahasa Indonesia untuk menganalisis opini masyarakat lokal secara lebih representatif.

2. Eksplorasi model transformer terkompresi (ONNX / WebAssembly) seperti TinyBERT atau ClimateBERT untuk meningkatkan akurasi semantik frasa majemuk.

3. Integrasi pemantauan live streaming API dengan filter bot/spam detection untuk menjaga keaslian opini pengguna manusia.

---