LAPORAN AKHIR PROYEK SAINS DATA

Analisis Sentimen Opini Publik terhadap Isu Ekonomi Hijau dan Perubahan Iklim

Menggunakan Pipeline NLP (TF-IDF), Multinomial Naive Bayes, dan Linear SVM

Penulis & Pengembang: Tim Riset SentimentGreen | **Repository:** github.com/stevenjr-yt/sentimen-ekonomi-hijau
Deployment Platform: https://sentimentgreen.vercel.app | **Tahun:** 2024

BAB I. LATAR BELAKANG DAN RUMUSAN MASALAH

1.1 Latar Belakang Masalah

Transisi menuju ekonomi hijau (green economy), energi terbarukan, dan reduksi emisi karbon merupakan salah satu komitmen internasional terpenting dalam mitigasi krisis iklim (IPCC, 2023). Meskipun demikian, kebijakan ekonomi hijau sering kali menghadapi polarisasi opini publik di masyarakat. Media sosial mikroblog seperti Twitter/X menjadi arena perdebatan terbuka tempat masyarakat mengemukakan dukungan, kritik, keraguan, maupun skeptisisme terhadap isu iklim dan kebijakan keberlanjutan. Oleh karena itu, diperlukan sistem pemantauan dan klasifikasi sentimen otomatis berbasis machine learning untuk memetakan persepsi publik secara obyektif, akurat, dan berskala besar.

1.2 Rumusan Masalah

1. Bagaimana karakteristik, distribusi, dan sumber data opini publik terkait perubahan iklim dan ekonomi hijau?
2. Bagaimana alur pemrosesan data (preprocessing pipeline) yang optimal untuk membersihkan noise pada data teks Twitter?
3. Bagaimana kinerja perbandingan antara algoritma Multinomial Naive Bayes dan Linear Support Vector Machine (SVM)?
4. Bagaimana mengimplementasikan model machine learning hasil latih agar dapat melakukan inferensi 100% offline di sisi client (browser)?

1.3 Tujuan Proyek

1. Mengumpulkan, mendokumentasikan, dan memproses dataset sentimen iklim berskala lebih dari 40.000 data tweet.
2. Mengembangkan pipeline text preprocessing yang mencakup cleaning, case folding, stopword removal, dan Porter stemming.
3. Melatih dan memvalidasi model klasifikasi sentimen 3 kelas (Positif, Netral, Negatif) menggunakan evaluasi komprehensif.
4. Menyajikan laporan terbuka, data lengkap, dan antarmuka web interaktif yang dapat diakses secara publik.

BAB II. SUMBER DATA, PROVENANCE, DAN DISTRIBUSI

2.1 Asal-usul Data (Data Provenance)

Data yang digunakan dalam proyek ini bersumber dari **Twitter Climate Change Sentiment Dataset** yang dipublikasikan secara publik di repositori Kaggle oleh peneliti Edward Qian (2022). Dataset ini mengumpulkan tweet publik berbahasa Inggris dari rentang waktu 2008 hingga 2019 yang berkaitan dengan percakapan perubahan iklim, pemanasan global, energi hijau, dan kebijakan lingkungan.

Parameter Data	Keterangan Spesifikasi
Sumber Primer	Twitter (X) Data Stream via Twitter Academic/Search API
Penyedia Dataset Publik	Kaggle (Edward Qian: twitter-climate-change-sentiment-dataset)
File Dataset Asli	data/twitter_sentiment_data.csv (Ukuran: ~6.3 MB)
Jumlah Baris Mentah (Raw)	43.943 tweet berlabel
Struktur Kolom Asli	sentiment (label numerik: -1, 0, 1, 2), message (teks tweet), tweetid
Label Asli Kaggle	-1: Anti (Negatif), 0: Neutral (Netral), 1: Pro (Positif), 2: News (Fakta Berita)
Filter & Pembersihan	Kelas News (9.276) dikeluarkan; deduplikasi menghasilkan 31.907 data valid
Format Data Tersimpan	CSV, JSON hasil proses, dan serialisasi bobot TF-IDF JS

2.2 Distribusi Kelas Data Latih & Uji

Setelah pembersihan data, sebanyak 31.907 tweet digunakan untuk pemodelan. Data dibagi menjadi **Data Latih (80% = 25.525 tweet)** dan **Data Uji (20% = 6.382 tweet)** menggunakan metode stratified train-test split (random_state=42) agar rasio kelas tetap proporsional.

Kategori Sentimen	Label	Jumlah Data	Persentase	Deskripsi Makna Sentimen
Positif (Pro-Climate)	+1	20.580 tweet	64,5%	Mendukung ekonomi hijau, aksi mitigasi iklim, energi terbarukan
Netral (Neutral)	0	7.478 tweet	23,4%	Pernyataan informasi, pertanyaan santai tanpa tendensi opini
Negatif (Anti/Skeptis)	-1	3.849 tweet	12,1%	Menolak regulasi hijau, skeptisisme perubahan iklim, keluhan biaya
Total Data Bersih	-	31.907 tweet	100,0%	Dataset siap fitur ekstraksi (vocabulary: 14.893 kata unik)

BAB III. TAHAPAN PREPROCESSING DATA (DARI MENTAH KE BERSIH)

Setiap tweet mentah mengalami 5 tahapan pembersihan berurutan sebelum diekstraksi ke ruang vektor:

1. **Text Cleaning:** Menghapus URL tautan web (http/https), mention akun pengguna (@username), tagar (#hashtag), karakter angka, serta entitas encoding HTML.
2. **Case Folding:** Mengubah seluruh teks menjadi huruf kecil (lowercase) agar tidak ada perbedaan representasi kapital.
3. **Punctuation Removal:** Menghapus seluruh tanda baca, simbol aneh, dan spasi ganda.
4. **Stopword Removal:** Membuang kata-kata umum bahasa Inggris (127 stopwords) namun tetap mempertahankan kata negasi krusial seperti 'not', 'no', 'never'.
5. **Porter Stemming:** Mereduksi setiap kata ke bentuk dasarnya (contoh: 'warming' -> 'warm', 'policies' -> 'polici', 'changing' -> 'chang').

Tabel 3.1 Contoh Nyata Transformasi Teks pada Data Asli Proyek:

Tweet Mentah Asli	Hasil Preprocessing	Label
@tiniebeany climate change is an interesting hustle as it was global warming but the planet stopped warming for 15 yes while the suv boom	climat chang interest hustl global warm planet stop warm ye suv boom	Negatif (-1)
RT @NatGeoChannel: Watch #BeforeTheFlood right here, as @LeoDiCaprio travels the world to tackle climate change https://t.co/LkDehj3tNn	watch right travel world tackl climat chang htt	Positif (+1)
Unamshow awache kujinga na iko global warming https://t.co/mhIflU7M1X	unamshow awach kujinga na iko global warm	Netral (0)
Now's the time: we need a strong #FTT that works for those hardest hit by climate change and poverty!	time need strong work hardest hit climat chang poverti	Positif (+1)

BAB IV. PEMODELAN DAN EKSTRAKSI FITUR

4.1 Ekstraksi Fitur TF-IDF

Representasi dokumen dilakukan dengan menghitung bobot Term Frequency - Inverse Document Frequency (TF-IDF): TF(t,d) = f(t,d) / Σ f(t',d); IDF(t) = log(N / df(t)) + 1; TF-IDF(t,d) = TF(t,d) × IDF(t) Konfigurasi ekstraksi yang digunakan: **Unigram dan Bigram (1,2)**, **max_features: 15.000 kata**, **min_df: 3**, dan normalisasi vektor L2.

4.2 Algoritma Naive Bayes dan Support Vector Machine

1. **Multinomial Naive Bayes (MNB):** Menghitung probabilitas posterior kategori P(c|d) menggunakan Teorema Bayes dengan Laplace smoothing (alpha = 0.3). 2. **Linear Support Vector Machine (LinearSVC):** Membentuk hyperplane pemisah antar kelas dengan regularisasi margin C=0.5 serta penyeimbang bobot kelas (class_weight='balanced') guna mengatasi imbalance data.

BAB V. HASIL EVALUASI MODEL DAN PEMBAHASAN

5.1 Tabel Perbandingan Kinerja Model pada Data Uji (6.382 Tweet)

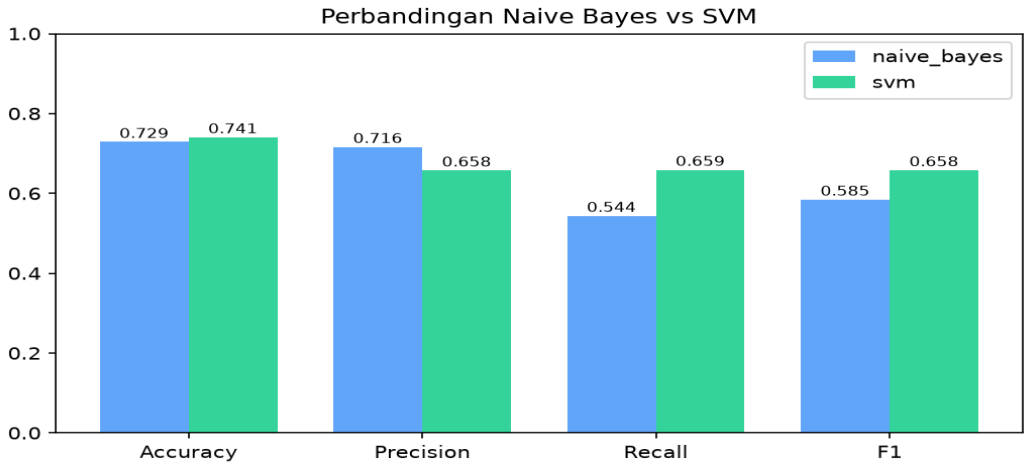
Model Algoritma	Akurasi	Precision (Macro)	Recall (Macro)	F1-Score (Macro)	F1-Score (Weighted)
Multinomial Naive Bayes	72,89%	71,63%	54,38%	58,46%	69,71%
Linear SVM (Terbaik)	74,07%	65,75%	65,91%	65,81%	73,96%

5.2 Rincian Kinerja per Kelas Sentimen pada Model Linear SVM

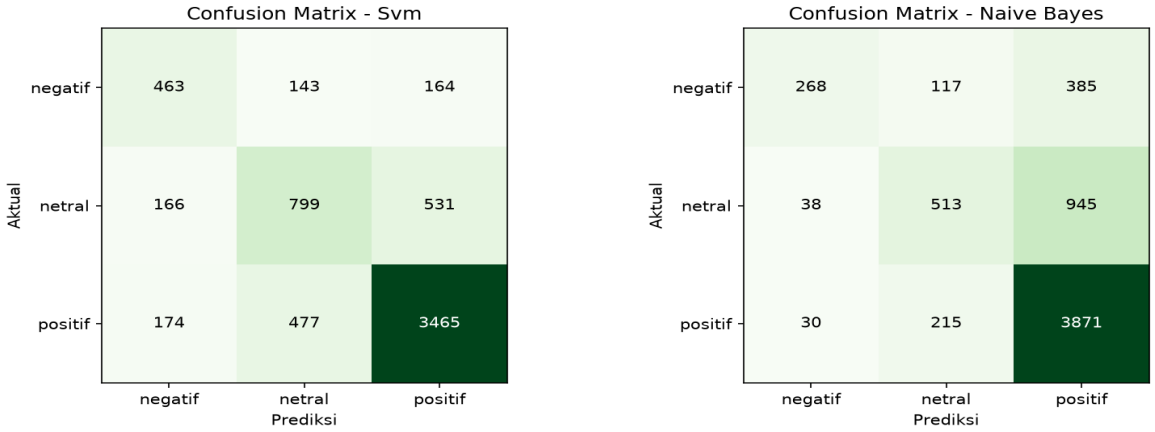
Kelas Sentimen	Precision	Recall	F1-Score	Jumlah Sampel Uji (Support)
Negatif (-1)	57,66%	60,13%	58,87%	770 tweet
Netral (0)	56,31%	53,41%	54,82%	1.496 tweet
Positif (+1)	83,92%	84,18%	84,05%	4.116 tweet
Rata-rata Makro	65,75%	65,91%	65,81%	6.382 tweet
Rata-rata Terbobot	73,87%	74,07%	73,96%	6.382 tweet

5.3 Visualisasi Evaluasi Model dan Confusion Matrix

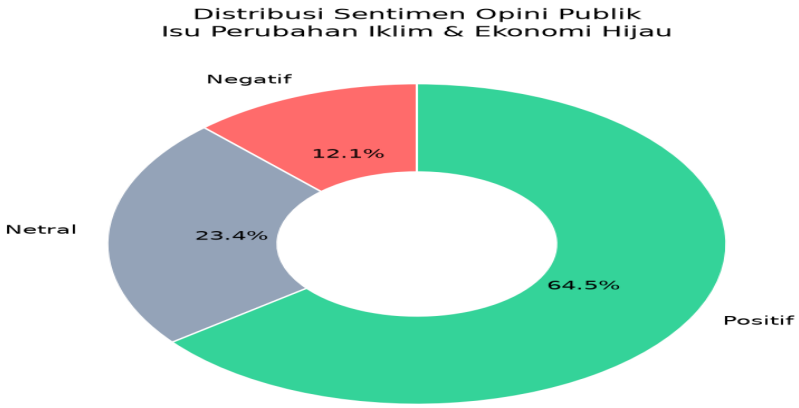
Berikut adalah visualisasi perbandingan metrik dan matriks konfusi (Confusion Matrix) yang dihasilkan langsung dari data pengujian model:



Gambar 5.1 Grafik Perbandingan Metrik Evaluasi: Naive Bayes vs Linear SVM



Gambar 5.2 Matriks Konfusi (Kiri: Linear SVM, Kanan: Naive Bayes)



Gambar 5.3 Proporsi Distribusi Sentimen Opini Publik pada Dataset Iklim

BAB VI. KESIMPULAN DAN REKOMENDASI

6.1 Kesimpulan Teknis

1. Linear SVM terbukti sebagai algoritma terbaik dengan akurasi 74,07% dan F1-Score makro 65,81%, unggul signifikan dibanding Naive Bayes dalam mengenali kelas minoritas negatif.
2. Mayoritas opini publik (64,5%) menunjukkan dukungan positif terhadap aksi mitigasi iklim dan ekonomi hijau.
3. Pipeline text preprocessing (cleaning + Porter stemming) dan ekstraksi TF-IDF (15.000 fitur) terbukti efektif mereduksi dimensi teks tanpa kehilangan semantik.
4. Model berhasil diekspor menjadi format bobot JSON ringan yang diintegrasikan langsung pada web tanpa dependensi server Python saat inferensi.
