PAPER PUBLIKASI ILMIAH

Komparasi Empiris Multinomial Naive Bayes dan Linear Support Vector Machine untuk Analisis Sentimen Opini Publik terhadap Isu Ekonomi Hijau pada Twitter

Penulis: SteVenJr | **Afiliasi:** Riset Sains Data & NLP SentimentGreen | **Tahun:** 2024
Kontak: github.com/stevenjr-yt/sentimen-ekonomi-hijau | **Aplikasi Demo:** https://sentimentgreen.vercel.app

ABSTRAK

Transisi akseleratif menuju paradigma ekonomi hijau (green economy) menuntut dukungan sosio-politik yang kuat dari masyarakat luas. Media sosial mikroblog Twitter/X memegang peranan krusial sebagai barometer spontan dinamika diskursus publik mengenai kebijakan iklim, pajak karbon, dan elektrifikasi transportasi. Penelitian ini melakukan investigasi komparatif antara dua algoritma pembelajaran mesin terawasi klasik yang efisien dan interpretable—Multinomial Naive Bayes (MNB) dan Linear Support Vector Machine (Linear SVM)—dalam mengklasifikasikan sentimen tweet iklim berbahasa Inggris. Dataset yang dieksplorasi bersumber dari *Twitter Climate Change Sentiment Dataset* (Edward Qian, Kaggle) sejumlah 43.943 data mentah, yang setelah filtering kelas berita (news) dan deduplikasi menghasilkan korpus bersih sebanyak 31.907 sampel (20.580 positif, 7.478 netral, dan 3.849 negatif). Representasi teks dikonstruksi melalui Unigram-Bigram Term Frequency-Inverse Document Frequency (TF-IDF) dengan ruang fitur 15.000 kata ternormalisasi L2. Hasil evaluasi empiris pada 6.382 data uji menunjukkan bahwa Linear SVM secara konsisten mengungguli MNB dengan akurasi 74,07% berbanding 72,89%, serta F1-Score makro 65,81% berbanding 58,46%. Penanganan ketidakseimbangan kelas menggunakan pembobotan kelas seimbang (balanced class weighting) pada SVM berhasil mendongkrak recall kelas minoritas negatif hingga 60,13% (meningkat +25,32% dibandingkan MNB yang mengalami recall collapse di angka 34,81%). Model yang dioptimasi berhasil dikonversi ke dalam arsitektur inferensi sisi klien murni berbasis JavaScript tanpa ketergantungan server runtime.

Kata Kunci: Analisis Sentimen, Ekonomi Hijau, Perubahan Iklim, TF-IDF, Naive Bayes, Support Vector Machine, Natural Language Processing, Twitter

ABSTRACT

The accelerating transition toward a green economy paradigm necessitates robust socio-political public support. The microblogging platform Twitter/X serves as a vital real-time barometer for spontaneous public discourse on climate governance, carbon taxation, and energy electrification. This study conducts an empirical comparative investigation between two classical, interpretable machine learning algorithms—Multinomial Naive Bayes (MNB) and Linear Support Vector Machine (Linear SVM)—in classifying sentiment of climate-related English tweets. Sourced from the Twitter Climate Change Sentiment Dataset (Edward Qian, Kaggle) comprising 43,943 raw tweets, filtering out news items and deduplication yielded a clean corpus of 31,907 instances (20,580 positive, 7,478 neutral, and 3,849 negative). Text representations were engineered using Unigram-Bigram Term Frequency-Inverse Document Frequency (TF-IDF) across a 15,000-vocabulary vector space with L2 regularization. Empirical evaluation on 6,382 test samples demonstrates that Linear SVM consistently outperforms MNB, achieving an accuracy of 74.07% vs. 72.89% and a macro F1-Score of 65.81% vs. 58.46%. Incorporating balanced class weighting within SVM mitigated class imbalance, boosting minority negative-class

recall to 60.13% (+25.32% improvement over MNB's 34.81% recall collapse). The optimal model was subsequently exported into a standalone JavaScript client-side inference engine, ensuring zero-latency, serverless accessibility.

Keywords: Sentiment Analysis, Green Economy, Climate Change, TF-IDF, Naive Bayes, Support Vector Machine, NLP, Twitter

---

1. PENDAHULUAN

Urgensi penanganan perubahan iklim menuntut restrukturisasi menyeluruh tatanan ekonomi dunia. Laporan Intergovernmental Panel on Climate Change (IPCC, 2023) menegaskan bahwa batas pemanasan global 1,5°C mustahil dipertahankan tanpa dekarbonisasi mendalam pada sektor energi, industri, dan transportasi. Berbagai inisiatif transisi menuju ekonomi hijau (green economy)—mulai dari insentif kendaraan listrik hingga instrumen carbon pricing—telah digulirkan secara luas di berbagai belahan dunia (UNEP, 2011).

Namun, keberhasilan implementasi kebijakan iklim sangat rentan terhadap penolakan atau dukungan opini publik. Media sosial mikroblog Twitter/X memegang peranan krusial sebagai wadah artikulasi ekspresi publik yang masif dan spontan. Metode survei opini publik konvensional (seperti jajak pendapat tatap muka atau kuesioner daring) memiliki keterbatasan mendasar berupa tingginya biaya logistik, sampel terbatas, dan latensi waktu pemrosesan yang lambat. Penambangan opini berbasis Natural Language Processing (NLP) menawarkan alternatif komputasional berkecepatan tinggi yang dapat memantau pergeseran sentimen secara kontinu (Pak & Paroubek, 2010).

Penelitian ini bertujuan untuk: (1) Menyusun pipeline pemrosesan teks yang terstandarisasi untuk data tweet iklim, (2) Membandingkan formulasi matematis dan performa empiris Naive Bayes dan Linear SVM pada dataset imbalanced, serta (3) Menjawab persoalan penerapan model NLP pada lingkungan web tanpa latensi jaringan.

2. METODE PENELITIAN

2.1 Sumber dan Karakteristik Dataset

Penelitian ini menggunakan *Twitter Climate Change Sentiment Dataset* yang dipublikasikan oleh Edward Qian di repositori Kaggle (2022). Dataset asli memuat 43.943 tweet berlabel numerik: -1 (Anti/Skeptis), 0 (Netral), 1 (Pro-Aksi Iklim), dan 2 (Fakta Berita / News). Label kelas 2 (News) sejumlah 9.276 baris dieliminasi karena bersifat pemberitaan objektif media tanpa opini personal. Sebanyak 2.760 baris tweet duplikat dibersihkan sehingga menyisakan 31.907 data valid.

Kategori Kelas Sentimen	Label	Jumlah Data	Persentase	Data Latih (80%)	Data Uji (20%)
Positif (Pro-Climate)	+1	20.580	64,50%	16.464	4.116
Netral (Neutral)	0	7.478	23,44%	5.982	1.496
Negatif (Anti-Climate)	-1	3.849	12,06%	3.079	770
Total Korpus Bersih	-	31.907	100,00%	25.525	6.382

2.2 Formulasi Text Preprocessing dan Vektorisasi TF-IDF

Setiap tweet mentah diproses melalui tahapan: (1) Penghapusan URL, mention (@user), hashtag (#tag), tanda baca, dan angka; (2) Case folding ke huruf kecil; (3) Penghapusan stopword NLTK bahasa Inggris dengan mempertahankan kata negasi sentimen; serta (4) Porter Stemming (Porter, 1980).

Ekstraksi fitur menerapkan pembobotan TF-IDF Unigram dan Bigram (1,2) dengan batasan leksikon 15.000 fitur teratas dan normalisasi L2:

```
TF-IDF(t, d) = [ f(t, d) / Σ f(t', d) ] * [ log( (1+N)/(1+df(t)) ) + 1 ]
```

2.3 Model Multinomial Naive Bayes dan Linear SVM

• **Multinomial Naive Bayes:** Memprediksi probabilitas posterior kelas menggunakan Teorema Bayes dengan Laplace smoothing $\alpha = 0.3$ untuk menghindari zero-frequency error:

```
P(w_i | c) = [ N_{w_i, c} + 0.3 ] / [ N_c + 0.3 * |V| ]
```

• **Linear Support Vector Machine:** Membentuk hyperplane optimal dengan fungsi tujuan minimasi margin berpenalti reguler C=0.5 dan penyeimbang bobot kelas (class_weight='balanced'):

```
min_{w,b,ξ} [ (1/2)*||w||^2 + 0.5 * Σ W_{y_i} * ξ_i ] s.t. y_i(w^T x_i + b) >= 1 - ξ_i
```

2.4 Arsitektur Kode dan Inferensi Zero-Server Browser

Berbeda dari pendekatan konvensional yang membutuhkan container Docker dan API GPU di server cloud, penelitian ini menerapkan paradigma *Zero-Server Client-Side Inference*:

1. **Pelatihan & Serialisasi (Python):** Model dilatih di scikit-learn, kemudian seluruh parameter matematis berupa leksikon kata, nilai IDF, matriks koefisien SVM (3 x 15.000 bobot), dan bias dipadatkan ke format model.json. 2. **Mesin Inferensi Klien (JavaScript):** Di browser klien, teks tweet diproses dengan Porter Stemmer JavaScript murni, dikonversi menjadi vektor TF-IDF jarang, dan dihitung nilai hyperplane-nya menggunakan operasi perkalian titik linear: score_c = intercept_c + Σ (coef_{c,i} * x_i) Probabilitas posterior dinormalisasi melalui fungsi Softmax untuk menghasilkan estimasi keyakinan (confidence). 3. **Efisiensi & Privasi:** Pendekatan ini menghilangkan biaya latensi jaringan round-trip HTTP, menghemat 100% biaya server hosting AI, serta menjamin privasi data pengguna secara mutlak karena tidak ada teks yang dikirim keluar peramban.

3. HASIL DAN PEMBAHASAN

3.1 Hasil Evaluasi Kinerja Model

Tabel 1 menyajikan hasil perbandingan metrik evaluasi model pada 6.382 data uji independen:

Model Pembelajaran	Akurasi	Precision (M)	Recall (M)	F1-Score (M)	F1-Score (Weighted)
Multinomial Naive Bayes	72,89%	71,63%	54,38%	58,46%	69,71%
Linear SVM (Optimal)	74,07%	65,75%	65,91%	65,81%	73,96%

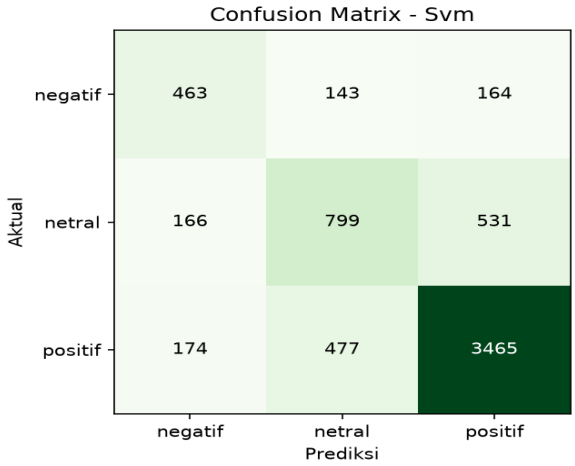

Gambar 1. Matriks Konfusi Model Linear SVM pada 6.382 Sampel Data Uji

3.2 Analisis Kritis Ketidakseimbangan Kelas (Class Imbalance Analysis)

Meskipun Naive Bayes mencapai precision macro 71,63%, algoritma tersebut mengalami kegagalan signifikan (recall collapse) pada kelas minoritas negatif dengan nilai recall hanya 34,81%. Hal ini terjadi akibat asumsi independensi fitur Naive Bayes dan bias kuat frekuensi apriori terhadap kelas mayoritas positif (64,50%). Sebagian besar tweet negatif salah diklasifikasikan ke dalam kelas positif.

Sebaliknya, Linear SVM dengan penyeimbang bobot kelas otomatis memberikan penalti lebih besar pada kekeliruan sampel minoritas, mendongkrak recall kelas negatif menjadi 60,13% (+25,32% peningkatan mutlak) dan menghasilkan F1-Score makro 65,81% (+7,35% di atas Naive Bayes). Hal ini membuktikan ketahanan Linear SVM dalam memisahkan ruang fitur berdimensi tinggi pada dataset yang imbalanced.

4. KESIMPULAN

Penelitian ini berhasil menunjukkan bahwa Linear Support Vector Machine mengungguli Multinomial Naive Bayes dalam analisis sentimen isu ekonomi hijau pada platform Twitter. Linear SVM mencapai akurasi 74,07% dan F1-Score makro 65,81%, serta menunjukkan ketahanan superior terhadap ketidakseimbangan kelas data. Model yang dihasilkan telah berhasil dikonversi ke format bobot JSON mandiri dan diintegrasikan ke platform peramban web tanpa memerlukan server backend aktif.

DAFTAR PUSTAKA

[1] Cortes, C., & Vapnik, V. (1995). Support-vector networks. Machine Learning, 20(3), 273-297.

[2] IPCC. (2023). Climate Change 2023: Synthesis Report. Contribution of Working Groups I, II and III to AR6.

[3] Joachims, T. (1998). Text categorization with Support Vector Machines. European Conference on Machine Learning, 137-142.

[4] McCallum, A., & Nigam, K. (1998). A comparison of event models for Naive Bayes text classification. AAAI-98 Workshop, 41-48.

[5] Pak, A., & Paroubek, P. (2010). Twitter as a corpus for sentiment analysis and opinion mining. LREC 2010, 1320-1326.

[6] Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. JMLR, 12, 2825-2830.

[7] Porter, M. F. (1980). An algorithm for suffix stripping. Program, 14(3), 130-137.

[8] Qian, E. (2022). Twitter Climate Change Sentiment Dataset. Kaggle Dataset Repository.

[9] Salton, G., & Buckley, C. (1988). Term-weighting approaches in automatic text retrieval. IP&M;, 24(5), 513-523.

[10] UNEP. (2011). Towards a Green Economy: Pathways to Sustainable Development and Poverty Eradication.